Excel, Python

Por: Isidora Cortes. Ingeniería en Informática.

Búsqueda y Filtrado de Archivos

Data-E

¿Qué significa buscar y filtrar?

Imagina que Data-E tiene un Excel con 10.000 estudiantes y necesita responder preguntas como:

- ¿Qué estudiantes pertenecen a Informática?
- ¿Cuáles tienen un promedio mayor o igual a 6,0?
- ¿Qué estudiantes están activos y pertenecen a una carrera específica?
- ¿Qué estudiantes pertenecen a Psicología o Derecho?

Podríamos hacer estas búsquedas manualmente usando los filtros de Excel, pero con Pandas podemos automatizarlas.



Código

```
from pathlib import Path
import pandas as pd
from openpyxl.styles import Alignment, Font, PatternFill
from openpyxl.workbook.properties import CalcProperties
from openpyxl.utils import get_column_letter
```

- El código utiliza tres librerías principales de Python:

- **pathlib (módulo Path):** Permite trabajar con rutas de archivos y carpetas de forma segura y compatible con cualquier sistema operativo (Windows, Mac, Linux) sin preocuparse por las barras inclinadas (/ o \).
- **pandas (como pd):** Es la librería estándar de Python para la manipulación y análisis de datos.
- **openpyxl:** Es la librería que usa Pandas por debajo para interactuar con archivos de Excel (.xlsx). Específicamente se importan complementos de estilo y configuración:
  - **Alignment, Font, PatternFill:** Sirven para cambiar la estética de las celdas (centrar texto, cambiar tipos de letra, tamaños, negritas y colores de fondo).
  - **CalcProperties:** Configura cómo Excel recalcula las fórmulas al abrir el archivo.
  - **get_column_letter:** Utilidad para convertir números de columnas en letras (por ejemplo, la columna 1 se convierte en "A").

Código

```
carpeta = Path(__file__).resolve().parent.parent
archivo = carpeta / "data" / "estudiantes_practica_30(1).xlsx'
```

- Localización: Se obtiene la ruta de la carpeta donde está guardado el script de Python para buscar dentro de una subcarpeta llamada data el archivo de Excel. Si no encuentra la versión con (1), intenta buscar el nombre limpio. Si no encuentra ninguno, lanza un error (FileNotFoundError).
- Carga y validación: Lee la hoja llamada "Estudiantes" del Excel con pd.read_excel() y comprueba que contenga todas las columnas obligatorias (ID_Estudiante, Nombre, Carrera, etc.). Si falta alguna, el programa se detiene y te avisa mediante un ValueError.

Código

Lo importante:

- Se crea un nuevo archivo de Excel llamado reporte_filtrado_data_e.xlsx.
- Se guarda una copia de la tabla original en una hoja llamada "Base original".
- Mediante un bucle (for), se recorre la lista de filtros creada antes y cada resultado se guarda en su propia hoja independiente dentro del archivo Excel.

```
salida = carpeta / "leccion_02" / "reporte_filtrado_data_e.xlsx"
with pd.ExcelWriter(salida, engine="openpyxl", date_format="DD/MM/YYYY", datetime_
    # Guardamos una copia de la tabla original como referencia.
    df.to_excel(writer, sheet_name="Base original", index=False)
```



A1 | DATA-E | REPORTE DE BUSQUEDA Y FILTRADO

DATA-E | REPORTE DE BUSQUEDA Y FILTRADO

Fuente: estudiantes_practica_30.xlsx | Los filtros mantienen los registros originales

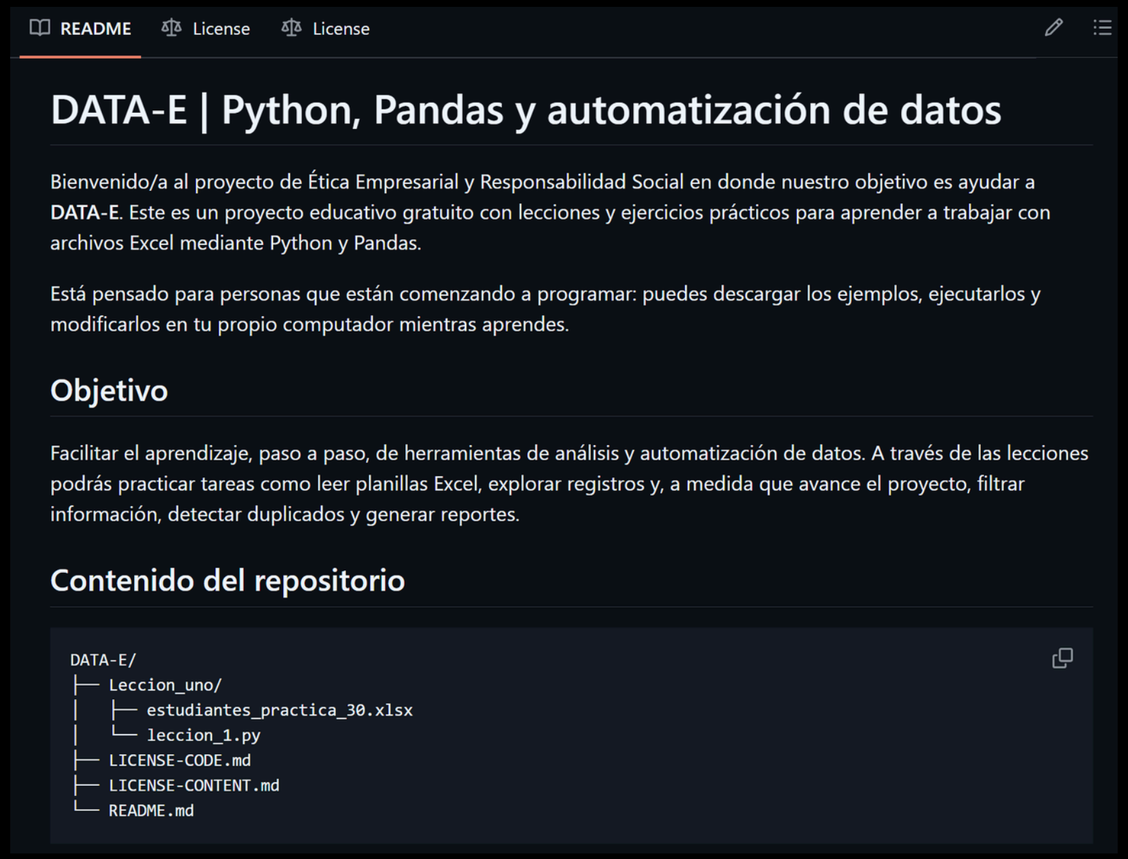
Conjunto de datos	Condicion del filtro	N. de registros
Base original	Todos los registros cargados	30
Activos prom 6	Estado = Activo y Promedio >= 6,0	9
Informatica	Carrera = Informatica	5
Activos Informatica	Carrera = Informatica y Estado = Activo	4
Psicologia Derecho	Carrera en Psicologia o Derecho	11
Activos con beca	Estado = Activo y Beca = Si	15
Ingreso 2025	Anio_Ingreso = 2025	6
Buscar ana	Nombre contiene "ana"	1
Datos faltantes	Promedio o Asistencia_Pct sin dato	2
IDs repetidos	ID_Estudiante repetido	2

Resumen | Base original | Activos prom 6 | Informatica | Activos Informati

GITHUB

Enlace Repositorio:
Usuario: nubecodev
https://github.com/nubecodev/DATA-E

Se subirá el material clase a clase.



¡Gracias!